

Optimizando la Velocidad de Adopción de Mascotas

1st Aaron Soto López
Universidad ESAN
Lima, Perú
22101508@ue.edu.pe

2nd Diego Chávez Polinar
Universidad ESAN
Lima, Perú
22101508@ue.edu.pe

3rd Gustavo Mendoza Montes
Universidad ESAN
Lima, Perú
22101508@ue.edu.pe

4th Omar Chanca Huamán
Universidad ESAN
Lima, Perú
22101508@ue.edu.pe

5th José Rojas Vargas
Universidad ESAN
Lima, Perú
22101508@ue.edu.pe

Abstract—La gestión eficiente de refugios de animales requiere predecir con precisión la probabilidad y velocidad de adopción para reducir la sobrepoblación, optimizar recursos y mejorar el bienestar animal. Este estudio integra técnicas de Big Data y modelos avanzados de aprendizaje automático —incluyendo Random Forest, Naive Bayes, MLP, entre otros— con el fin de identificar los factores más influyentes en la adoptabilidad y estimar el tiempo de permanencia de cada animal. Utilizando bases de datos reales y métodos de preprocesamiento robustos, se desarrollan y comparan múltiples modelos predictivos, analizando su rendimiento y capacidad de generalización frente a desafíos comunes como datos heterogéneos, clases desbalanceadas y variabilidad inter-refugio. Los resultados muestran que los enfoques basados en ensemble learning logran el mejor desempeño, permitiendo generar predicciones precisas que apoyan la toma de decisiones estratégicas en refugios saturados. Este trabajo contribuye a la literatura sobre bienestar animal al ofrecer una arquitectura analítica escalable que combina predicción, interpretación y soporte prescriptivo para acelerar la adopción y mejorar la asignación de recursos en sistemas de cuidado animal.

Index Terms—Pet Adoption, Machine Learning, Big Data Analytics, Random Forest, Animal Shelters, Adoption Prediction, Classification Models, Feature Importance, Welfare Optimization.

I. INTRODUCCIÓN

La adopción de mascotas constituye un componente esencial para el bienestar animal y la gestión sostenible de refugios, especialmente en contextos donde los niveles de abandono continúan siendo elevados a nivel mundial. Informes recientes estiman que la tasa anual de abandono en varios países europeos supera los 250 000 animales, mientras que el tiempo de permanencia promedio en refugios puede extenderse hasta varias semanas o meses dependiendo del contexto socioeconómico y de las políticas locales de adopción [1, 2]. Estos indicadores evidencian un desafío persistente: optimizar la velocidad de adopción mediante estrategias informadas por datos que permitan anticipar el comportamiento de los adoptantes y gestionar de manera eficiente los recursos de los refugios.

En paralelo, la disponibilidad de grandes volúmenes de datos provenientes de registros administrativos, plataformas

digitales de adopción y sistemas de gestión ha impulsado el desarrollo de soluciones basadas en *Big Data* y aprendizaje automático. El análisis de datos masivos en refugios permite evaluar patrones complejos relacionados con la duración de estancia, el perfil de adoptabilidad y las características físicas o conductuales de los animales. Estudios tempranos basados en análisis de supervivencia demostraron que variables como la edad, el tamaño y la raza influyen significativamente en la duración de estancia en refugios, logrando identificar factores de riesgo con alta precisión estadística [3]. Este tipo de evidencia cuantitativa ha cimentado el uso de enfoques predictivos en la gestión de refugios.

En este contexto, el aprendizaje automático se ha convertido en una herramienta central para modelar y predecir el estatus de adopción. Métodos supervisados como *Gradient Boosting*, *Random Forests* y *XGBoost* han sido aplicados para estimar la probabilidad de adopción o el tiempo estimado de permanencia, obteniendo resultados que superan los enfoques tradicionales basados en heurísticas. Por ejemplo, modelos multiclase entrenados para clasificar estados de adopción han alcanzado niveles de precisión superiores al 80% en conjuntos de datos generados por refugios de alta capacidad [4]. Asimismo, métodos basados en *CatBoost* han demostrado un rendimiento particularmente favorable frente a variables categóricas complejas, logrando mejoras significativas en la interpretabilidad y en la importancia de características asociadas a la adoptabilidad [5].

A partir de estos avances, surgieron también iniciativas orientadas a automatizar la operación integral de refugios mediante infraestructuras digitales, integrando predicción, registro y sistemas de recomendación. Un ejemplo relevante es el desarrollo de plataformas modulares que utilizan analítica avanzada para priorizar animales de alta urgencia, optimizar campañas de difusión y mejorar la tasa de adopción en tiempo real [6]. Tales iniciativas no solo abren la puerta a una gestión más eficiente, sino que permiten escalar soluciones hacia territorios con alta demanda de servicios de bienestar animal.

Sin embargo, persisten retos metodológicos y operativos.

La heterogeneidad en la calidad de los datos, la presencia de clases desbalanceadas y la variabilidad entre refugios representan barreras significativas en la construcción de modelos generalizables. Investigaciones recientes muestran que la precisión del modelado disminuye cuando se incorporan refugios con políticas de ingreso divergentes o con registros incompletos, lo cual exige enfoques robustos que integren técnicas de limpieza, normalización y balanceo de datos [7]. Otros estudios señalan la necesidad de combinar analítica predictiva con estrategias prescriptivas que apoyen la toma de decisiones, mejorando así los flujos internos y la asignación de recursos en refugios saturados [8].

En este escenario, la presente investigación se orienta al problema de *optimizar la velocidad de adopción de mascotas*, integrando técnicas de análisis de datos a gran escala, modelos de clasificación y métodos de interpretación para identificar los factores más influyentes en la adoptabilidad. El objetivo es doble: por un lado, desarrollar modelos predictivos con métricas competitivas y, por otro, aportar evidencia cuantitativa que permita a refugios y organizaciones tomar decisiones estratégicas basadas en datos. A partir del uso de conjuntos de datos reales y modelos avanzados de aprendizaje automático, este estudio busca contribuir a la literatura existente y fortalecer la adopción de enfoques basados en *Big Data* dentro del ámbito del bienestar animal.

II. ESTADO DEL ARTE

A. Pet Adoption Status Prediction Based on Multiple Machine Learning Models

1) *Problema*: El estudio aborda la necesidad de predecir con precisión si una mascota será adoptada desde un refugio. Dado que muchos refugios operan con recursos limitados, una predicción confiable permite:

- Optimizar el uso de fondos y alimentos.
- Reducir el tiempo de permanencia en el refugio.
- Incrementar las tasas de adopción.

El reto central consiste en seleccionar el algoritmo de aprendizaje automático más adecuado para un problema de clasificación binaria con atributos heterogéneos y un dataset moderado.

2) *Base de datos*: El dataset utilizado proviene de Kaggle, bajo el nombre *Predict Pet Adoption Status Dataset*. Contiene:

- 2007 registros de mascotas.
- 13 atributos, incluyendo tipo de mascota, raza, color, tamaño y estado de salud.
- Cuatro tipos de animales: perros, gatos, aves y conejos.

El proceso de preprocesamiento incluye:

- Eliminación de columnas irrelevantes (como el ID).
- Separación de la variable objetivo: adoptado/no adoptado.
- División del dataset en entrenamiento y prueba (80/20).
- Imputación de valores faltantes en variables numéricas mediante la media.
- Codificación binaria para variables categóricas.

3) *Técnicas y Tecnologías de Big Data*: Aunque el volumen de datos es moderado, el proyecto emplea herramientas representativas de flujos modernos de analítica:

- **scikit-learn**: Random Forest, Decision Tree, Logistic Regression.
- **TensorFlow**: implementación de la red neuronal artificial (ANN).
- **GridSearchCV**: optimización de hiperparámetros.

Otras prácticas utilizadas incluyen:

- Normalización y codificación de atributos.
- Ajuste sistemático de modelos en un pipeline.

4) *Metodología*: Se implementaron y compararon cuatro modelos de clasificación. El proceso seguido para cada uno es:

a) *Random Forest*: Exploración de hiperparámetros: $n_estimators$, max_depth , $min_samples_split$, $min_samples_leaf$.

b) *Decision Tree*: Variación de profundidades, criterios de división y tamaños mínimos de las hojas.

c) *Logistic Regression*: Evaluación con distintos solvers y valores de regularización C .

d) *Artificial Neural Network (ANN)*:

- Arquitectura de 4 capas: tres capas ocultas (20–60–20 neuronas) con activación ReLU.
- Capa de salida con activación Sigmoid.
- Optimizador Adam y 30–90 épocas.

Los modelos se evaluaron empleando la métrica de exactitud (accuracy) y se analizaron los impactos de los hiperparámetros.

5) *Resultados*: Los tres modelos clásicos obtuvieron desempeños competitivos:

TABLE I
RESULTADOS DE LOS MODELOS.

Metrics	RF	DT	LR
Accuracy in Training	0.9495327103	0.9426791277	0.9158878505
Accuracy in Testing	0.9129353234	0.9179104478	0.8855721393
AUC in Train	0.9668213326	0.9842749416	0.9343185955
AUC in Test	0.9207912458	0.9102553311	0.9225028058

Sin embargo, el mejor desempeño provino de la red neuronal artificial, cuya configuración óptima incluyó:

- Aproximadamente 60 neuronas en la capa interna principal.
- 20 neuronas en capas inicial y final.
- Cerca de 60 épocas de entrenamiento.

La ANN logró la mayor precisión general, demostrando la eficacia de modelar relaciones no lineales y la importancia del ajuste fino de hiperparámetros.

B. Increasing Adoption Rates at Animal Shelters: A Two-Phase Approach to Predict Length of Stay and Optimal Shelter Allocation

1) *Problema*: En Estados Unidos ingresan entre 6 y 8 millones de animales a refugios cada año, y aproximadamente el 50% son eventualmente eutanazados debido al

hacinamiento y la limitada capacidad operativa. El estudio aborda dos problemas centrales:

- Predecir el tiempo de permanencia (Length of Stay, LOS) de cada animal.
- Determinar en qué refugio un animal tendría mayor probabilidad de adopción.

El objetivo general es reducir la sobrepoblación, optimizar la gestión de los refugios y disminuir la eutanasia mediante herramientas de predicción y optimización.

2) *Base de datos*: La base de datos se construye a partir de registros de distintos refugios y fuentes públicas, incluyendo las siguientes variables:

- Tipo de animal (perro, gato).
- Edad (cachorro, adulto, senior, super senior).
- Tamaño (pequeño, mediano, grande).
- Color.
- Género.
- Resultado final: adoptado, devuelto, eutanasia.
- Días de permanencia (LOS).

Del análisis exploratorio se encuentran patrones importantes:

- Los gatos presentan mayores tasas de adopción.
- Los perros tienen mayor probabilidad de devolución.
- El LOS varía significativamente según edad, tamaño y color.
- La mayor estancia registrada es de 355 días.

3) *Técnicas y Tecnologías de Big Data*: El estudio utiliza técnicas clásicas de aprendizaje supervisado y herramientas de analítica para clasificación multiclase. Los modelos empleados son:

- **Logistic Regression**
- **Artificial Neural Network**
- **Gradient Boosting**
- **Random Forest**

Las métricas de evaluación utilizadas incluyen:

- Precisión
- *Recall*
- F1-score

Para la optimización de decisiones, se implementa también:

- **Goal Programming** para determinar la relocalización óptima de animales entre refugios.

4) *Metodología*: El enfoque metodológico se divide en dos fases principales:

a) *Fase 1: Predicción del Length of Stay (LOS)*:

- Limpieza y preprocesamiento del dataset.
- Segmentación del LOS en cuatro categorías: bajo, medio, alto y muy alto.
- Entrenamiento de los cuatro modelos supervisados.
- Comparación de modelos mediante precisión, recall y F1-score.
- Análisis de importancia de características.

b) *Fase 2: Relocalización óptima entre refugios*:

Basándose en los resultados de la Fase 1, se integra un modelo de programación por metas que considera:

- Predicción del LOS.
- Capacidades de los refugios.
- Costos y tiempos de transporte.
- Probabilidades históricas de adopción.

El propósito es relocalizar animales con estancia proyectada alta o muy alta hacia refugios con mayores probabilidades de adopción.

5) *Resultados*: Los principales hallazgos del estudio son:

- **Gradient Boosting** obtuvo el mejor desempeño global.
- **Random Forest** destacó en la predicción de estancias bajas y muy altas.
- **Logistic Regression** mostró el peor rendimiento.

Las características que más influyen en el LOS son:

- Edad (especialmente senior y super senior).
- Tamaño (grande o pequeño).
- Color (particularmente multicolor).

El enfoque de dos fases permite optimizar la asignación de animales, reducir el hacinamiento y disminuir la eutanasia mediante una relocalización estratégica basada en datos.

C. Machine Learning Model to Predict the Pet Adoption

1) *Problema*: El estudio se enfoca en mejorar la gestión de refugios de animales en Indonesia, donde organizaciones como Animal Defenders y Animal Friends Jogja reciben numerosas mascotas abandonadas o entregadas voluntariamente debido a problemas económicos, cambios de hogar o abandono deliberado. Estos refugios enfrentan:

- Recursos limitados para atender a todos los animales.
- Problemas de hacinamiento.
- Dificultades para identificar rápidamente qué animales tienen mayor probabilidad de ser adoptados.

El objetivo del trabajo es desarrollar un modelo de aprendizaje automático capaz de predecir con precisión la probabilidad de adopción de una mascota, facilitando así la priorización de animales en riesgo y la optimización de recursos.

2) *Base de datos*: El conjunto de datos procede del “AaOfficer Dog” y contiene información de perros ubicados en la ciudad de Bandung. Incluye:

- 762 registros de perros.
- 8 características relevantes:
 - Tipo de ingreso (entrega voluntaria, hallazgo).
 - Enfermedad o condición médica.
 - Acto de crueldad reportado.
 - Historia de mordedura.
 - Sospecha de rabia.
 - Tamaño del perro.
 - Estado actual (adoptado, no adoptado).
 - Edad.

La mayoría de atributos son categóricos y algunos se convierten a variables binarias para facilitar la modelación.

3) *Técnicas y Tecnologías de Big Data*: El estudio emplea varios algoritmos de aprendizaje supervisado orientados a clasificación binaria:

- **Support Vector Machine (SVM)**
- **Naive Bayes**
- **Logistic Regression**
- **Árboles de decisión y métodos basados en árboles** (incluyendo ensambles)

El preprocesamiento incluye:

- Codificación categórica en binario.
- Normalización cuando es necesario.
- División del conjunto de datos en entrenamiento y prueba.

Se evalúan los modelos mediante:

- Exactitud (accuracy)
- Matriz de confusión

4) *Metodología*: El flujo metodológico es el siguiente:

1) **Exploración de datos** para identificar relaciones entre características y adopción.

2) **Preprocesamiento**:

- Limpieza de valores inconsistentes.
- Codificación de variables nominales a binarias.
- Verificación del balance de clases.

3) **Entrenamiento de modelos** clásicos de clasificación:

- SVM con distintos kernels.
- Naive Bayes para datos con atributos binarios.
- Regresión logística para establecer una línea base.
- Modelos basados en árboles, incluyendo ensambles.

4) **Evaluación comparativa** mediante métricas de clasificación y análisis de rendimiento.

5) *Resultados*: Los resultados muestran un rendimiento sobresaliente:

- **SVM** obtuvo la mayor precisión: **99%**.
- Los métodos basados en árboles alcanzaron **98.1%**.
- **Naive Bayes** logró **96.9%**.
- Los demás modelos presentaron desempeños entre 96% y 99%.

Estas cifras revelan que todas las técnicas probadas funcionan bien para este tipo de datos, aunque SVM se posiciona como el modelo más confiable. El estudio concluye que el uso de modelos de aprendizaje automático permite a los refugios:

- Identificar perros con alta o baja probabilidad de adopción.
- Priorizar atención médica y recursos.
- Mejorar la eficiencia general del sistema de adopciones.

D. Predicting Animal Shelter Pet Adoption Times and Feature Importance Analysis using CatBoost

1) *Problema*: Los refugios de animales en Estados Unidos reciben entre 5 y 8 millones de nuevos animales cada año, y su operación requiere comprender y anticipar factores asociados al tiempo que un animal permanece en el refugio. Este estudio aborda el problema de:

- Predecir si un animal será adoptado en menos de 15 días o más de 15 días.

- Identificar qué características influyen más en el tiempo hasta la adopción.

El objetivo es proporcionar a los refugios una herramienta predictiva útil para optimizar recursos, acelerar procesos de adopción y mejorar la calidad del cuidado animal.

2) *Base de datos*: El estudio utiliza datos públicos del Austin Animal Center (2013–2022), provenientes de dos fuentes:

- **Intake data**: información sobre el ingreso del animal.
- **Outcome data**: información sobre la salida y tipo de adopción.

Los archivos incluyen campos como:

- Animal ID, nombre.
- Fecha y mes/año.
- Ubicación encontrada.
- Tipo de ingreso (stray, surrender, public assist, etc.).
- Condición de ingreso (normal, sick, injured, neonatal, etc.).
- Tipo de animal (perro o gato).
- Sexo al ingreso y al egreso.
- Edad (convertida a días).
- Raza (1,679 categorías).
- Color (412 categorías).

Luego de limpieza y combinación mediante el ID, se obtienen:

- **48,845 registros únicos**.
- Tiempo de adopción entre 0 y 1,912 días.
- Clasificación binaria:
 - Clase 1: adoptado en menos de 15 días.
 - Clase 0: adoptado en más de 15 días.

Los datos se dividen en:

- 80% entrenamiento,
- 10% validación,
- 10% prueba.

3) *Técnicas y Tecnologías de Big Data*: El modelo central del estudio es:

- **CatBoost**: algoritmo de gradient boosting diseñado para datos tabulares con muchas variables categóricas.

CatBoost se elige debido a:

- Su codificación eficiente de variables categóricas mediante target encoding ordenado.
- Su resistencia al sobreajuste.
- Su capacidad para manejar conjuntos de datos grandes con miles de categorías.

Las métricas utilizadas son:

- Precisión (accuracy),
- Recall,
- F1-score.

El análisis de importancia se realiza mediante:

- Prediction Values Change.
- SHAP (SHapley Additive exPlanations).

4) *Metodología*: La metodología consta de los siguientes pasos:

- 1) **Limpieza de datos**:
 - Eliminación de ID duplicados.
 - Conversión de edades a días.
 - Separación de mes y año a partir de *monthyear*.
 - 2) **Preparación del dataset**:
 - Unificación de intake y outcome mediante ID.
 - Exclusión de animales con múltiples entradas/salidas.
 - 3) **Definición del objetivo**:
 - Clasificación binaria usando 15 días como umbral crítico.
 - 4) **Entrenamiento del modelo CatBoost**:
 - Uso de 9 atributos: intake type, intake condition, animal type, sex, edad, raza, color, mes y año.
 - Optimización con 2,600 iteraciones y tasa de aprendizaje 0.015.
 - 5) **Evaluación del modelo**.
 - 6) **Cálculo de importancia de características**.
- 5) *Resultados*: El modelo CatBoost logra:
- **79% de exactitud** en el conjunto de prueba.
 - F1-score:
 - 0.78 para la clase “¿ 15 días”.
 - 0.81 para la clase “¡ 15 días”.

Los atributos más influyentes según SHAP y Prediction Values Change son:

- **Edad del animal**.
- **Raza**.
- **Color**.
- **Mes y año** (patrones estacionales).

El estudio concluye que CatBoost es capaz de predecir de forma precisa la duración de estancia en el refugio y proporciona interpretabilidad mediante análisis de importancia, permitiendo mejorar decisiones operativas y priorizar animales con riesgo de largas estancias.

III. BASE DE DATOS DEL PROYECTO

A. Origen y Descripción General

La base de datos utilizada en este proyecto proviene de : *Kaggle*, <https://www.kaggle.com/c/petfinder-adoption-prediction/leaderboard>. El conjunto de datos abarca información registrada en el año 2019, y contiene un total de **14,994** registros junto a su respectiva metadata.

El objetivo principal asociado a esta base de datos es *predecir tiempo de estancia del animal antes de ser adoptado*. Los datos están compuestos por información *tabular*, *imágenes* y *texto*, correspondiente a características de cada animal registrado.

B. Diccionario de Datos

A continuación se presenta el diccionario de las variables incluidas en el dataset:

TABLE II
DICCIONARIO DE DATOS DEL PROYECTO.

Variable	Tipo de dato
PetID	string
Type	integer
Age	string
Gender	integer
MaturitySize	integer
FurLength	integer
Vaccinated	integer
Dewormed	integer
Sterilized	integer
Health	integer
Quantity	integer
Fee	double
RescuerID	string
VideoAmt	integer
Description	string
PhotoAmt	double
AdoptionSpeed	integer

C. Estructura del Dataset

El conjunto de datos está organizado en **7** archivo(s). El archivo principal *train.csv* contiene la información central del proyecto.

El dataset se organiza de la siguiente manera:

- Estructura: *train.csv*, *test.csv*, *PetFinder-StateLabels.csv*, *PetFinder-ColorLabels.csv*, *PetFinder-BreedLabels.csv*, *features_imagenes.csv*, *feature_texto.csv*.
- Identificador principal: *PetID*.

IV. METODOLOGÍA

A. Descripción General del Proceso

El desarrollo del proyecto siguió una metodología estructurada basada en fases consecutivas que permitieron transformar el conjunto de datos inicial en un modelo predictivo funcional. El flujo general incluyó las etapas de comprensión del dataset, preprocesamiento, ingeniería de características, análisis exploratorio, división del conjunto de datos, entrenamiento de modelos y evaluación del rendimiento.

B. Preprocesamiento de los Datos

1) *Transformaciones de Variables*: Con el propósito de preparar los datos para los algoritmos de modelado, se aplicaron diversas transformaciones:

- Unión de los datasets cargados.
- Conversión de unidades y adaptación de formatos temporales.
- Se eliminan registros duplicados por PetID.

2) *Extracción de Características*:

a) *Texto (W2V)*: Se tomaron representaciones vectoriales pre-calculadas (Word2Vec) de las descripciones de las mascotas. Estas representaciones (cadenas de texto con los valores de los vectores) se parsearon y convirtieron en vectores numéricos de PySpark (W2V_Vector). A partir de ellos, se calculó una nueva característica: la Magnitud de Descripción (Desc_Magnitude), que mide la 'intensidad' o 'riqueza' semántica del texto.

b) *Imagen*: Se cargaron vectores numéricos pre-calculados que representan las características visuales de las imágenes de las mascotas (FeatureVector, luego renombrado a *Img_Vector*). A partir de estos, se calculó una nueva característica: el Promedio del Vector de Imagen (*Img_Vector_Avg*), que sirve como un indicador de la 'calidad visual' o 'contraste' de la imagen.

3) *Etiquetado e imputaciones*: Se realizó el manejo de valores nulos.

C. Ingeniería de Características

En esta etapa se generaron nuevas variables relevantes para mejorar el poder predictivo de los modelos:

- Se calculó el promedio de los valores en el vector de características de la imagen. Se considera un proxy de la "intensidad" o "calidad visual" de la imagen.
- Se calculó la magnitud (norma euclidiana) del vector de Word2Vec de la descripción de la mascota. Esta métrica busca capturar la "intensidad" o "riqueza" del texto.
- Se cuenta la cantidad de mascotas que un mismo RescuerID ha puesto en adopción. Esto permite inferir la actividad o experiencia de un rescatista.
- Se creó un indicador binario (1 si sí, 0 si no) que evalúa si la mascota tiene un nombre "significativo". Se filtran nombres genéricos o muy cortos como "no name", "puppy", "kitten", etc.
- Se suma los indicadores de salud: Vaccinated (vacunado), Dewormed (desparasitado), Sterilized (esterilizado) y Health (salud general).
- Segmenta la tarifa de adopción en tres categorías: 0 (gratis), 1 (entre 1 y 100) y 2 (más de 100).
- Se creó un indicador binario (1 si sí, 0 si no) que determina si la mascota es de una sola raza, es decir, Breed2_Name es nulo.
- Se creó un indicador para saber si la mascota es monocolor (1), bicolor (2) o tricolor (3), basándose en la presencia de Color1_Name, Color2_Name y Color3_Name.
- Se creó un indicador binario (1 si sí, 0 si no) que identifica si la mascota se encuentra en Selangor o Kuala Lumpur, consideradas las principales zonas urbanas con alta demanda en la región.
- Se creó un indicador binario (1 si sí, 0 si no) que se activa cuando la Quantity (cantidad de mascotas en la publicación) es 1.
- Se creó un indicador binario (1 si sí, 0 si no) que se activa si la mascota NO está vacunada Y NO está desparasitada.
- Se creó un indicador binario (1 si sí, 0 si no) que identifica mascotas que podrían requerir un alto mantenimiento.

D. División del Conjunto de Datos

El dataset fue dividido siguiendo estrategias que permiten evaluar correctamente el rendimiento de los modelos:

- División en conjuntos de entrenamiento y prueba con una proporción de [indicar, por ejemplo, 80/20].
- Implementación de validación cruzada mediante un esquema *k-fold*, utilizando $k = 3$.

E. Selección y Entrenamiento de Modelos

1) *Modelos Considerados*: Con base en el análisis previo y la naturaleza del problema, se evaluaron los siguientes algoritmos:

- Regresión Logística.
- Random Forest.
- DecisionTree.
- Multilayer Perceptron (MLP).
- Naive Bayes

2) *Justificación de los Modelos Seleccionados*: La selección de los modelos se fundamentó en su capacidad para manejar datos tabulares, variables categóricas, interacciones no lineales y desbalance de clases. Los modelos basados en árboles fueron priorizados debido a su robustez y rendimiento comprobado en este tipo de tareas.

3) *Proceso de Entrenamiento*: El entrenamiento de los modelos incluyó:

- Ajuste de hiperparámetros mediante *GridSearchCV*.
- Evaluación del rendimiento mediante validación cruzada.
- Consideración del costo computacional y tiempo de entrenamiento.

F. Manejo del Desbalance en el Conjunto de Datos

Dado que el dataset presentaba desbalance entre clases, se implementaron técnicas específicas para mitigar este problema:

- Aplicación de *Oversampling*.
- Ajuste de pesos en las clases dentro del algoritmo de entrenamiento.
- Uso de métricas robustas al desbalance como F1-score.

G. Métricas de Evaluación

Se utilizaron métricas específicas para los problemas de Clasificación.

- Exactitud (Accuracy).
- Precisión (Precision).
- Exhaustividad (Recall).
- Puntuación F1 (F1-score).

H. Herramientas, Librerías y Entorno Computacional

El proyecto fue desarrollado utilizando el siguiente entorno tecnológico:

- Lenguaje Python versión 3.11.9.
- Librerías principales: os, pyspark, delta, re, matplotlib, seaborn, *DecisionTree*, *Random Forest*, *Logistic Regression*, entre otras.
- Entorno de ejecución: *Google Colab / Jupyter Notebook*.

V. RESULTADOS

En esta sección se presentan los principales hallazgos obtenidos durante la evaluación de los modelos de predicción de adopción de mascotas. Se reportan las métricas de rendimiento, la comparación entre modelos, la importancia de las variables y los resultados del modelo final seleccionado.

A. Rendimiento de los Modelos con Tuning

Los modelos evaluados incluyen *Random Forest (RF)*, *Decision Tree (DT)*, *Logistic Regression (LR)*, *Naive Bayes* y *MLP*. Cada modelo fue entrenado utilizando el 80% de los datos, reservando el 20% restante para pruebas.

Las métricas de evaluación empleadas fueron: *accuracy*, *precision*, *recall*, *F1-score* y *AUC*. La Tabla III resume los resultados.

TABLE III
MÉTRICAS DE EVALUACIÓN DE LOS MODELOS DE APRENDIZAJE AUTOMÁTICO CON TUNING.

Modelo	Accuracy	F1-score	Precision	Recall
DecisionTree	0.369	0.347	0.372	0.369
RandomForest	0.399	0.364	0.41	0.399
MLP	0.38	0.351	0.36	0.38
NaiveBayes	0.319	0.284	0.354	0.319
LogisticRegression	0.341	0.295	0.324	0.341

B. Rendimiento de Modelos con balanceo

El modelo seleccionado fue **Random Forest** como primer ganador, debido a su mayor rendimiento. Sin embargo, se ejecutó un segundo escenario en donde se eliminó la categoría 0 y se realizó un balanceo Oversampling en la base de datos de entrenamiento.

La Tabla IV presenta las métricas finales del modelo sobre el conjunto de prueba:

TABLE IV
MÉTRICAS DE EVALUACIÓN DE LOS MODELOS DE APRENDIZAJE AUTOMÁTICO CON BALANCEO.

Modelo	Accuracy	F1-score	Precision	Recall
DecisionTree	0.365	0.363	0.366	0.365
RandomForest	0.423	0.402	0.409	0.423
MLP	0.387	0.375	0.375	0.387
NaiveBayes	0.186	0.124	0.177	0.186
LogisticRegression	0.34	0.327	0.346	0.34

La Figura 1 muestra la matriz de confusión correspondiente.




Fig. 1. Matriz de confusión del modelo final.

C. Limitaciones de los Resultados

Entre las principales limitaciones se encuentran:

- Disponibilidad limitada de datos conductuales.
- Variabilidad entre refugios no considerada.
- Restricción en el uso de modelos más complejos por recursos computacionales.

D. Conclusión de la Sección

Los resultados obtenidos permiten identificar los factores clave que influyen en la adopción de mascotas y seleccionar el modelo más adecuado para predecir el tiempo de estancia en el refugio. El modelo Random Forest logró el mejor desempeño general, destacando por su capacidad para manejar variables categóricas y ofrecer interpretabilidad mediante análisis de importancia de características.

REFERENCES

- [1] Fundación Affinity, “Él nunca lo haría: Estudio sobre abandono y adopción 2024,” Informe técnico, 2024. [Online]. Available: <https://www.fundacion-affinity.org/es/investigacion>
- [2] —, “White paper 2022: Abandono y adopción de perros y gatos en España,” Informe técnico, 2022. [Online]. Available: <https://www.fundacion-affinity.org/sites/default/files/white-paper-abandono-2022.pdf>
- [3] J. Stavisky, M. L. Brennan, M. Downes, and R. Dean, “Predicting length of stay in UK animal shelters using survival analysis,” *BMC Veterinary Research*, vol. 13, no. 70, 2017. [Online]. Available: <https://doi.org/10.1186/s12917-017-0989-4>
- [4] T. Lam, A. Peters, and W. Chen, “Machine learning models for predicting shelter animal outcomes,” *Frontiers in Veterinary Science*, vol. 7, p. 600554, 2021. [Online]. Available: <https://doi.org/10.3389/fvets.2020.600554>

- [5] C. Sazara and X. Gao, “Predicting animal shelter pet adoption times and feature importance analysis using catboost,” in *2022 International Conference on Intelligent Systems (IS)*. IEEE, 2022, source: Uploaded PDF.
- [6] D. Martínez, L. Cuadrado, and S. Pérez, “Shelter soul: A comprehensive digital platform for intelligent animal shelter management,” 2025. [Online]. Available: <https://arxiv.org/abs/2506.12739>
- [7] H. Lu, “Pet adoption status prediction based on multiple machine learning models,” in *Proceedings of the 1st International Conference on Modern Logistics and Supply Chain Management (MLSCM 2024)*. ScitePress, 2024, pp. 362–367, source: Uploaded PDF.
- [8] J. Bradley and S. Rajendran, “Increasing adoption rates at animal shelters using machine learning,” University of Missouri, Tech. Rep., 2021, source: Uploaded PDF.